



TUGAS BESAR



ILMU DAN

ANALITIKA DATA

KELOMPOK 3

Alfi Mutawakkil Marwan	2410932008
Afif Gardana	2410932009
Suroso Aditya Wibowo	2410932036





Pokok Pembahasan

Problem industri, KPI, baseline, dan keputusan yang ingin diambil

Data Source, unit analisis, data dictionary, isu kualitas data

Cleaning dan Transformasi penting

EDA dan 3-5 visualisasi utama

Model/statistik/inferensi dan alasan memilih metrik

Hasil evaluasi, threshold atau confidence interval

Insight final dan rekomendasi operasional



Resiko implementasi, monitoring, dan next step.




PROBLEM INDUSTRI, KPI, BASELINE, DAN KEPUTUSAN YANG INGIN DIAMBIL

PROBLEM INDUSTRI

Kondisi yang berlangsung saat ini adalah perawatan mesin dilakukan secara reaktif. Teknisi baru bergerak setelah mesin berhenti atau setelah operator melaporkan keluhan. Rata-rata waktu respons dalam kondisi ini mencapai lebih dari 2 jam setelah downtime terjadi, sementara kerusakan komponen sebenarnya sudah berkembang jauh sebelum tanda-tanda fisik terlihat oleh operator.


KEPUTUSAN

Menentukan apakah suatu mesin perlu mendapatkan tindakan preventive maintenance sebelum downtime terjadi.
Kedua, memprioritaskan urutan penanganan ketika ada lebih dari satu mesin yang terdeteksi berisiko secara bersamaan.



KPI, BASELINE

KPI	Definisi	Rumus	Numerator	Denominator	Satuan	Baseline	Target
Downtime Recall	Mengukur kemampuan model dalam mendeteksi mesin yang benar-benar akan mengalami downtime dalam 24 jam ke depan. Recall menjadi metrik paling kritis karena biaya akibat downtime yang tidak terdeteksi lebih besar dibanding alarm palsu.	$Recall = TP / (TP + FN)$	True Positive (TP): jumlah mesin yang benar-benar akan downtime dan berhasil diprediksi oleh model.	TP + FN: seluruh mesin yang sebenarnya akan mengalami downtime pada periode pengujian.	%	82,35%	$Recall \geq 82,35\%$
False Alarm Rate (FAR)	Mengukur seberapa sering model memberikan alarm downtime padahal mesin sebenarnya dalam kondisi normal. FAR yang tinggi dapat menyebabkan <i>alarm fatigue</i> sehingga teknisi cenderung mengabaikan notifikasi.	$FAR = FP / (FP + TN)$	False Positive (FP): jumlah mesin yang diprediksi downtime tetapi kenyataannya tidak.	FP + TN: seluruh mesin yang sebenarnya tidak mengalami downtime.	%	0%	$FAR \leq 50\%$
Downtime Avoidance	Mengukur proporsi downtime yang berhasil dicegah melalui tindakan maintenance berdasarkan prediksi model. KPI ini dievaluasi setelah sistem diterapkan secara operasional.	$Downtime\ Avoidance = Downtime\ yang\ berhasil\ dicegah / Total\ downtime\ potensial$	Jumlah kejadian downtime yang berhasil dicegah karena tindakan preventif dilakukan sebelum waktu kritis.	Total downtime yang diperkirakan akan terjadi tanpa adanya intervensi.	%	0%	$\geq 50\%$



DATA SOURCE, UNIT ANALISIS, DATA DICTIONARY, ISU KUALITAS DATA



DATA SOURCE

Dataset yang digunakan adalah **dataset synthetic-realistic predictive maintenance** yang terdiri dari **2.400 baris observasi** dan **14 kolom**. Dataset ini sengaja mengandung isu kualitas data seperti missing value, outlier, dan nilai tidak valid agar proses profiling dan cleaning dapat dipraktikkan.

UNIT ANALISIS


Unit analisis adalah mesin-jam (machine-hour): setiap baris merepresentasikan kondisi satu mesin pada satu titik waktu observasi. Kolom `target_downtime_next_24h` menunjukkan apakah mesin tersebut mengalami downtime dalam 24 jam setelah titik observasi tersebut.



DATA DICTIONARY





Kolom	Tipe Awal	Deskripsi
timestamp	date/datetime atau kategori waktu	Waktu observasi.
machine_id	string/kategori	ID mesin. Gunakan untuk segmentasi dan analisis variasi antar mesin.
line	kategori	Lini produksi atau area operasi.
age_months	numeric/kategori	Kolom operasional. Definisi perlu dikaitkan dengan problem statement dan KPI.
last_maintenance_days	numeric	Kolom operasional. Definisi perlu dikaitkan dengan problem statement dan KPI.
temp_c	numeric	Temperatur proses atau mesin dalam derajat Celsius.
vibration_mm_s	numeric	Getaran mesin dalam mm/s. Nilai ekstrem dapat berarti gejala kerusakan atau error sensor.
current_a	numeric	Arus listrik mesin dalam ampere.
load_pct	numeric	Rasio atau persentase. Periksa denominator sebelum membuat agregasi.
lubricant_level_pct	numeric	Rasio atau persentase. Periksa denominator sebelum membuat agregasi.
alarm_count	numeric	Kolom operasional. Definisi perlu dikaitkan dengan problem statement dan KPI.
downtime_next_24h	binary 0/1	Target 1 jika mesin mengalami downtime dalam 24 jam berikutnya.
maintenance_ticket_closed	numeric/kategori	Status tiket setelah kejadian. Kolom ini tidak tersedia saat prediksi awal.
failure_mode	numeric/kategori	Kolom operasional. Definisi perlu dikaitkan dengan problem statement dan KPI.



ISU KUALITAS DATA





No	Isu Data	Temuan
1	Ketidaksesuaian Tipe Data	Kolom timestamp masih bertipe object/string, padahal seharusnya bertipe datetime untuk mendukung analisis berbasis waktu.
2	Missing Value	Terdapat 72 data kosong (missing value) pada kolom lubricant_level_pct.
3	Nilai Tidak Valid	Terdapat nilai pada kolom load_pct yang melebihi 100%, dengan nilai maksimum sebesar 105%.
4	Outlier	Ditemukan outlier pada kolom temperature_c, vibration_mm_s, current_a, load_pct, dan alarm_count.
5	Outlier Ekstrem	Kolom vibration_mm_s memiliki nilai maksimum sebesar 999 mm/s, jauh di atas nilai median sebesar 3,37 mm/s, sehingga diduga merupakan noise sensor atau kesalahan pencatatan data.
6	Class Imbalance	Distribusi target downtime_next_24h tidak seimbang antara kelas normal dan downtime.
7	Data Leakage	Kolom failure_mode dan maintenance_ticket_closed mengandung informasi yang baru diketahui setelah kejadian downtime, sehingga berpotensi menyebabkan data leakage.



CLEANING DAN TRANSFORMASI PENTING




No.	Kolom	Masalah yang Ditemukan	Tindakan Penanganan	Alasan
1	maintenance_ticket_closed, failure_mode	Data leakage	Dihapus	Informasi hanya tersedia setelah downtime terjadi sehingga dapat menyebabkan kebocoran informasi pada model prediksi.
2	lubricant_level_pct	Terdapat 72 missing values	Imputasi menggunakan median per machine_id	Data bersifat time-series sehingga penghapusan baris dapat mengurangi informasi; median per mesin lebih representatif dibanding median global.
3	load_pct	Terdapat nilai melebihi 100%	Nilai dibatasi menggunakan .clip(upper=100)	Nilai di atas 100% tidak sesuai dengan batas domain variabel dan dianggap sebagai error sensor.
4	vibration_mm_s	Terdapat outlier ekstrem (nilai maksimum 999 mm/s)	Nilai dibatasi menggunakan .clip(upper=persentil 99)	Nilai ekstrem diduga berasal dari noise atau kesalahan sensor sehingga tidak merepresentasikan kondisi operasional yang sebenarnya.
5	timestamp	Tipe data masih berupa object	Konversi ke tipe datetime menggunakan pd.to_datetime()	Diperlukan untuk analisis dan pemrosesan data berbasis waktu.



EDA


VIBRATION TREND



Insight

- Mesin yang sehat cenderung memiliki tingkat getaran yang stabil.
- Sebagian besar downtime terjadi setelah atau saat terjadi lonjakan getaran yang tidak normal.
- Hal ini menunjukkan bahwa getaran tinggi dapat menjadi indikator awal potensi kerusakan mesin.
- Namun, beberapa downtime terjadi tanpa peningkatan getaran yang jelas.


BOXPLOT SENSOR



Insight

- Temperature (temp_c): Mesin yang mengalami downtime cenderung memiliki suhu operasi lebih tinggi.
- Vibration (vibration_mm_s): Perbedaan paling jelas; mesin downtime menunjukkan getaran yang jauh lebih tinggi.
- Alarm Count (alarm_count): Mesin downtime cenderung menghasilkan lebih banyak alarm sebelum terjadi gangguan.
- Lubricant Level (lubricant_level_pct): Mesin downtime memiliki level pelumas yang lebih rendah.
- Load (load_pct): Distribusi relatif mirip antara kondisi normal dan downtime, sehingga kurang membedakan kedua kondisi.
- Current (current_a): Perbedaan sangat kecil, sehingga kontribusinya terhadap deteksi downtime tampak terbatas.


KORELASI



Insight


Alarm, getaran, dan keterlambatan perawatan merupakan faktor yang paling berpengaruh terhadap terjadinya downtime mesin.

DOWNTIME PER MESIN DAN PER LINI



Insight

Prioritas perbaikan sebaiknya difokuskan pada mesin MX-05, MX-11, MX-12, MX-08, dan MX-07, terutama pada lini L3 dan L4 yang memiliki tingkat downtime tertinggi.



Insight

Downtime pada L1, L3, dan L4 didominasi oleh beberapa mesin tertentu, sedangkan L2 menunjukkan performa yang paling konsisten dan stabil.

MODEL/STATISTIK/INFERENSI DAN ALASAN MEMILIH METRIK





MODEL YANG DIGUNAKAN

- **Logistic Regression** dipilih sebagai model baseline karena sederhana, mudah diinterpretasikan, dan sesuai untuk klasifikasi biner downtime.
- **Random Forest** dipilih sebagai model pembanding karena mampu menangkap hubungan non-linear dan interaksi antar fitur yang tidak dapat dimodelkan secara optimal oleh Logistic Regression.

METRIK YANG DIPILIH DAN ALASAN

- **Recall** digunakan untuk mengukur kemampuan model dalam mendeteksi seluruh kejadian downtime yang sebenarnya terjadi.
- **F1-Score** digunakan sebagai metrik pendukung karena mempertimbangkan keseimbangan antara Recall dan Precision.



HASIL EVALUASI, THRESHOLD ATAU CONFIDENCE INTERVAL





HASIL EVALUASI

=====				
=== BASELINE: Logistic Regression (threshold=0.50) ===				
	precision	recall	f1-score	support
Normal	0.98	0.74	0.84	458
Downtime	0.12	0.73	0.20	22
accuracy			0.74	480
macro avg	0.55	0.73	0.52	480
weighted avg	0.94	0.74	0.81	480
=====				
=== BASELINE: Random Forest (threshold=0.50) ===				
	precision	recall	f1-score	support
Normal	0.95	0.98	0.96	458
Downtime	0.00	0.00	0.00	22
accuracy			0.93	480
macro avg	0.48	0.49	0.48	480
weighted avg	0.91	0.93	0.92	480

HASIL TUNNING


=====				
=== FINAL: Logistic Regression (threshold=0.30) ===				
	precision	recall	f1-score	support
Normal	1.00	0.57	0.73	458
Downtime	0.10	0.95	0.18	22
accuracy			0.59	480
macro avg	0.55	0.76	0.45	480
weighted avg	0.95	0.59	0.70	480
=====				
=== FINAL: Random Forest (threshold=0.30) ===				
	precision	recall	f1-score	support
Normal	0.96	0.91	0.93	458
Downtime	0.12	0.27	0.17	22
accuracy			0.88	480
macro avg	0.54	0.59	0.55	480
weighted avg	0.92	0.88	0.90	480



HASIL EVALUASI, THRESHOLD ATAU CONFIDENCE INTERVAL






HASIL TUNNING



Model Logistic Regression Terpilih

FAKTOR YANG PERLU DIPERHATIKAN



INSIGHT FINAL DAN REKOMENDASI OPERASIONAL



INSIGHT FINAL

Insight 1 — alarm_count dan last_maintenance_days adalah dua sinyal risiko terkuat, dengan peran berbeda di EDA dan model

Insight 2 — vibration_mm_s dan temp_c melengkapi sinyal risiko dengan dukungan statistik yang signifikan



Insight 3 — Pelumas rendah berkorelasi negatif signifikan dan mencerminkan risiko mekanis yang dapat dicegah

Insight 4 — L3 dan L1 memiliki downtime rate tertinggi; L2 paling stabil dengan semua mesin di bawah rata-rata global

Insight 5 — Logistic Regression dengan threshold 0.30 mencapai Recall 95.5% dan dipilih sebagai model operasional; FAR 42.8% perlu dikelola aktif

REKOMENDASI OPERASIONAL



1. Integrasikan output model Logistic Regression ke sistem SCADA atau MES. Kirim notifikasi otomatis ke teknisi yang bertugas ketika probabilitas prediksi suatu mesin melampaui threshold 0.30.
2. Tetapkan aturan eskalasi alarm_count sebagai lapisan peringatan kedua yang tidak bergantung pada model.
3. Jadwalkan inspeksi lubricant_level_pct setiap 7 hari sekali dan tambahkan trigger otomatis jika level turun di bawah 30%.
4. Laksanakan audit menyeluruh terhadap MX-05 di L1 (downtime rate 5.0%) dan mesin-mesin bermasalah di L3 — MX-11 (4.0%) dan MX-07 (3.5%) — dalam 2 minggu ke depan, mencakup pemeriksaan kondisi fisik komponen, kalibrasi sensor, dan tinjauan prosedur operasi standar.




RESIKO IMPLEMENTASI, MONITORING, DAN NEXT STEP.



Aspek	Risiko	Monitoring	Next Step / Mitigasi
Model Drift	Performa model dapat menurun seiring perubahan kondisi mesin dan pola produksi.	Memantau Recall, Precision, F1-Score, dan FAR secara berkala.	Melakukan retraining model menggunakan data terbaru setiap periode tertentu.
False Alarm Fatigue	Alarm palsu yang terlalu banyak dapat mengurangi kepercayaan teknisi terhadap sistem.	Memantau jumlah false positive dan FAR pada kondisi operasional nyata.	Mengoptimalkan threshold prediksi untuk menyeimbangkan Recall dan FAR.
Kualitas Sensor	Data sensor yang rusak atau tidak valid dapat menghasilkan prediksi yang tidak akurat.	Memantau missing value, nilai tidak valid, dan anomali sensor.	Menambahkan validasi data otomatis dan kalibrasi sensor secara berkala.
Keamanan Data	Data sensor mengandung informasi sensitif terkait kondisi aset dan produksi perusahaan.	Memantau akses pengguna dan aktivitas penggunaan data.	Menerapkan kontrol akses, audit log, dan kebijakan retensi data.
Bias Data Historis	Model mungkin kurang optimal pada kondisi atau mesin tertentu yang jarang muncul dalam data pelatihan.	Mengevaluasi performa model per mesin dan per lini produksi.	Menambah data historis yang lebih beragam dan memperbarui model secara berkala.





THANK
YOU:)

